存储编码实验指导书

光电存储与 DNA 存储对比

适用课程：现代计算系统结构与算力技术

适用平台：存储编码离线实验 v3.2

实验形式：浏览器离线软件实验

本实验从字节表示出发，完成 DNA 编码、分片分析、信道模拟和独立解码。通过四项任务，解释同一份信息如何转换为不同存储表示，以及冗余、序列约束和错误类型如何影响可靠恢复。

实验任务与目标

任务	主要目标
1 数据表示与 DNA 基础编码	理解计算机数据从“字符/数值 → 字节 → 二进制 → DNA 碱基序列”的转换过程，掌握 Vanilla 双比特映射、Church 二选一映射的基本规则，并分析不同编码方案对序列长度的影响
2 分片、帧结构与 DNA 序列质量分析	理解分片的含义，帧结构，以及“有效载荷、片号、长度、CRC 检错、Hamming 纠错”之间的关系；初步认识 GC、同聚物和重复序列等 DNA 序列质量指标
3 DNA 信道错误模拟分析	理解 DNA 在合成、保存、PCR、抽样和测序过程中可能产生的替换、插入、删除和分片丢失等错误，并分析不同错误类型对数据恢复的影响

学习成果与实验报告要求

完成后应能选取任一分片，说明其原始字节、帧、ECC（纠错编码）和 DNA；再从实际读段说明恢复路径及校验结果。实验结论须由本次参数和报告支持，不以“结果成功”替代过程分析。

- ❑ 每个试验任务都要包含输入的原始文本及对应的 DNA 编码序列（截图或文本）。其中**原始文本不建议使用本实验指导书中的参考示例**。参考“观察与记录”或指导步骤中的内容进行实验报告撰写
- ❑ 涉及解码的实验，需提供解码验证结果截图
- ❑ 非实验内容 / 知识点：提交对比表格，任选一种传统存储与 DNA 存储在密度、寿命、读写速度、能耗四个维度进行数据对比，并提供数据来源
- ❑ 简短分析（200 以内）：DNA 存储最适合应用于什么场景？为什么？

一、 实验准备与总体流程

运行环境

1. 直接打开 HTML 文件。确认页眉版本为 v3.2。无需安装 Python、Node.js 或联网

2. 创建本地结果文件夹，分别保存 task1、task2、task3、task4。报告下载后及时添加组号或工况名，避免浏览器自动重命名导致混淆

3. 依次认识“01 数据编码” “02 信道模拟” “03 解码恢复” “04 算法对比”和“算法说明”。一般先执行编码，再模拟，最后解码；初次学习不使用“运行全流程”跳过观察。



图 1 本实验的数据处理流程

开始前统一参数

项目	基础设置
DNA 算法与纠错	Vanilla；无纠错（保留 CRC32 检错）
每片数据载荷	24 B；任务 2 的边界示例改为 8 B
编码和模拟随机种子	均为 42；实验中需记录实际值
前后缀	全部留空，避免固定序列影响长度与校验

输入文件最大 16 KiB；五算法比较的数据不超过 2 KiB。建议先用小样本理解流程，再做 256 字节对照。修改输入或编码参数后必须重新编码；修改信道参数后必须重新模拟；改变解码策略后必须重新解码。

文件与位置约定

FASTA 保存 DNA 序列，manifest.json 保存算法、纠错、分片大小、文件长度和 CRC 等恢复参数。独立解码需要二者。新报告的分片号、读段 ID 及字节区间从 0 开始，[a,b)包含 a 而不包含 b。界面中明确标注“从 1 开始”的字符或事件位置按其标注读取。

本平台模拟 DNA 数据处理，不进行真实 DNA 合成或光盘、磁盘读写。光电存储部分用于原理对照；浏览器耗时不能解释为真实介质读写速度。

二、 预备知识与存储表示

从介质表示到数据恢复

比较维度	光电存储的典型表示	本实验的 DNA 表示
信息单位	逻辑层仍以 bit 和 byte 表示	先得到字节，再映射为 A C G T
物理状态举例	光盘的光学反射差异； 闪存的电荷状态	DNA 分子的碱基顺序
记录与读取	写入介质并检测物理状态	概念上对应合成与测序； 本实验用软件模拟
可靠性机制	编码、检错、纠错与备份	分片、CRC、片内 ECC、多拷贝与可选共识
本次可测量内容	不测真实设备速度或寿命	编码长度、序列统计、模拟错误与恢复结果

“光电存储”在这里是光学存储和电子存储的概括，它们并不采用同一种物理机制。两类系统的共同点是：先表示信息，再加入组织和保护信息，读取时检查是否恢复正确。

本实验必须区分的概念

术语	含义与判断方法
bit 与 B	1 B = 8 bit。十进制 175 作为单字节是 AF；字符“175”则是三个字节。
nt	DNA 序列长度单位；本平台每个 A/C/G/T 计 1 nt。
载荷与帧	载荷是原文件的数据；帧还包含片号、长度、补零和 CRC。
CRC 与 ECC	CRC 用于检错；ECC 在规定条件与能力内纠正错误。CRC 通过不等于密码学安全认证。
分片与读段	分片是设计的数据单元；一个分片可有多个分子拷贝，并得到多条读段。
完整恢复	所有必要分片得到唯一有效载荷，且整文件 CRC 通过。

记录两个信息密度

纯映射密度 = 输入映射器的比特数 ÷ 编码主体碱基数。Vanilla 为 2 bit/nt；Church 为 1 bit/nt。

任务 1 数据表示与 DNA 基础编码

实验目标：掌握字符或数值到字节、二进制、碱基的转换，理解 Vanilla 双比特映射和 Church 二选一映射，并比较长度。

操作步骤

1. 在“01 数据编码”选择“单字节数值（0–255）”，输入 175。在“数字表示与基础 DNA 映射”查看第 0 字节，记录十六进制、二进制和双比特分组。

2. 保持 Vanilla、无纠错、每片载荷 24 B、前后缀空，执行编码。在分片内部结构和“文字与编码信息对应”中定位有效载荷的 DNA 区间。注意完整序列还包含帧字段，不能把完整 FASTA 当作 GGTT。

3. 切换为“文本（UTF-8）”，输入 175，不加引号或换行。重新编码，逐一查看 3 个字节。再输入字符 A，核对其字节表示。

4. 切回单字节数值模式，输入 175，再改为 Church，保持其余配置不变并重新编码。记录 175 这个单字节的实际映射及完整序列长度。可在“算法说明”的“亲手核对一个字节”中输入 175，查看纯映射与回译。

5. 下载“编码映射 HTML”，核对原字节、对应分片和实际 DNA。Church 使用随机选择，作业中保留实际种子和实际输出，不指定唯一答案。

手算示例

输入	字节与二进制	Vanilla 纯映射
数值 175	AF = 10101111；10 | 10 | 11 | 11	G G T T，共 4 nt
文本 175	31 37 35；00110001 00110111 00110101	ATAC ATCT ATCC，共 12 nt
字符 A	41 = 01000001；01 | 00 | 00 | 01	C A A C，共 4 nt

Church 按单比特映射：0 选 A 或 C，1 选 G 或 T，因此 1 B 需要 8 nt。例如 GAGAGTTT 可以表示 10101111；这是合法示意序列，平台的确定输出以实际种子和上下文为准。

观察与记录

在 24 B 固定载荷、无 ECC、空前后缀下，即使原始输入只有 1 B，完整帧仍为 31 B。Vanilla 完整片长为 124 nt；Church 为 248 nt。这里比较的是相同帧的映射开销。

记录：数值 175 原始大小 ____ B；文本 175 原始大小 ____ B；Church 实际序列 _____；Vanilla 完整长度 ____ nt；Church 完整长度 ____ nt。

思考：为什么更换随机种子可能改变 Church 的 DNA 序列，却不改变解码字节？为什么 1 B 原文件的净密度远小于 2 bit/nt?

验证长字节的恢复内容

1. 自行创建文件大小大于 12KB 但不超过 16KB 的 txt 文档，使用上传文件功能作为编码输入。

2. 选择 Vanilla、Hamming、载荷 24 B，执行编码；在解码输入中选“本次编码序列（无噪声）”，直接解码。核对完整恢复字节数、字符数与 CRC。

五算法控制变量比较

1. 恢复“载入 256 字节样本”、载荷 24 B、无纠错、空前后缀、编码种子 42。进入“04 算法对比”，每种算法重复 3 次，开始比较并下载 CSV。

2. 观察，并在实验报告中记录展示实验结果

任务 2 分片与帧结构

实验目标：理解分片的作用，以及有效载荷、片号、长度、CRC 与 Hamming 之间的关系；能够核对跨分片中文字符。

操作与逐片核对

1. 输入“1234567 中 A😀”（不含引号，不加换行），选择 Vanilla、无纠错、每片载荷 8 B、空前后缀，执行编码。原文件应为 15 B，共 2 片。

2. 在分片选择器中依次查看第 0 片和第 1 片。记录文件字节区间、有效长度、补零数、完整帧 HEX 和 DNA 长度。

3. 展开“按原文搜索定位分片”，搜索“中”。查看编码报告中的“该 UTF-8 字符跨分片边界”提示。汉字中占 E4 B8 AD 三个字节，其中第一个在片 0，另外两个在片 1。

4. 切换为 Hamming(8,4)，重新编码并保存第二份报告。比较原始数据大小、帧大小、ECC 后字节数和最终 DNA 长度。

分片	文件字节区间	有效载荷 HEX	有效长度	补零
0	[0,8)	31 32 33 34 35 36 37 E4	8 B	0 B
1	[8,15)	B8 AD 41 F0 9F 98 80	7 B	1 B

计算帧开销

每片完整帧 = 2 B 片号 + 1 B 有效长度 + B 字节载荷区域 + 4 B CRC32。因此帧长为 B+7，末片不足 B 时补零；CRC 覆盖片号、长度、载荷和补零。片号采用大端字节顺序。

配置	每片帧	ECC 后每片	每片 DNA	总 DNA	净密度
无纠错	15 B	15 B	60 nt	120 nt	1 bit/nt
Hamming	15 B	30 B	120 nt	240 nt	0.5 bit/nt

示例总原始信息量为 15×8=120 bit。Hamming 将每 4 个数据位扩展为 8 位，对整帧编码后字节数翻倍；有效原文件大小不变。不要把填充字节计为恢复的原文。

跨片字符的正确读法

字节分片不保证字符边界。片 0 末尾的 E4 单独不是完整汉字；不能将它独立 UTF-8 解码后出现的异常符号解释为原文损坏。字符辅助视图可能在相邻两片都显示完整的“中”，但实际存储字节没有重复。重组完整字节后才能正确还原文本。

任务 2 序列质量与纠错原理

序列质量观察

1. 保持 Vanilla、无纠错、载荷 24 B。分别输入 16 个 A 和 16 个 U，单独编码并保存报告。只比较两组相同长度输入，不额外加入空格或换行。

2. 在“DNA 序列质量分析报告”选择“编码主体（不含前后缀）”，查看 GC 分布和每片最长同聚物。记录整片统计，不只数载荷片段。

手算核对：ACGTACGT 的 GC 为 4/8=50%，最长同聚物为 1 nt，包含 ACGT 的串联重复。GGGGCCCC 的 GC 为 100%，最长同聚物为 4 nt。GC 接近 50%并不排除长同聚物或重复。

字符 U 的字节为 55，Vanilla 的载荷映射为 CCCC。16 个 U 会形成长 C 连续段，但完整 DNA 还包含片号、长度、补零与 CRC，不能把完整片的 GC 直接写成 100%。

输入及配置	GC	最长同聚物	观察结论
16 个 A 无 ECC	_____	_____ nt	_____
16 个 U 无 ECC	_____	_____ nt	_____
256 B 样本 无 ECC	_____	_____ nt	_____

Hamming 独立比特演示

1. 展开“Hamming(8,4) 原理演示”，保留 4 bit 数据 1011，先选择无错误，点击“编码、注入错误并解码”。记录 8 bit 码字 01100110。

2. 选择单 bit 错误，翻转第 5 位。接收码字应为 01101110；syndrome 为 5，整体奇偶检查异常，恢复后得到 1011。

3. 选择双 bit 错误，翻转第 5 和第 6 位。观察检测到错误但不能安全纠正。此演示独立于文件输入和 DNA 信道，不会自动改变后续实验参数。

能力边界：扩展 Hamming 每个 8 bit 码字可纠正 1 位、检测 2 位错误；3 位及以上不保证识别。一次 DNA 碱基替换在 Vanilla 下可能改变 1 个或 2 个比特，因此“1 个碱基错误”不等于“1 个可纠正 bit 错误”。

任务 3 信道错误的控制变量实验

实验目标：理解各阶段的错误与丢失，区分碱基变化、分子损失、整片缺失，分析它们如何影响解码。

统一实验样本与基线

使用“载入 256 字节样本”，Vanilla、载荷 24 B、空前后缀、编码种子 42；该样本应分为 11 片。先选择无纠错。在“02 信道模拟”点击“无噪声基线”，再逐项确认下表。预设可能同时改多个参数，不能仅凭按钮名称记录实验条件。

参数	基线值
每片初始拷贝数 与 PCR 轮数	2；0
整组丢失率	0%
合成替换 插入 删除	全部 0%
分子存活率 与 保存替换	100%；0%
每轮复制概率 与 新拷贝替换	100%；0%（PCR 为 0 轮时不生效）
抽样保留率	100%
测序替换 插入 删除	全部 0%
模拟随机种子 与 共识	42；关闭

逐组操作

每次只改表中指定项，其余返回基线。先执行信道模拟，再到“03 解码恢复”选择“本次模拟读段”，执行解码。保存报告后再进入下一组。换纠错配置必须回编码页重新编码，随后重新模拟。

工况	ECC	相对基线的唯一变化	重点观察
G0	无	无	全部分片和文件 CRC
G1	无	测序替换 1%	帧拒绝与错误事件
G2	Hamming	测序替换 1%	纠正数及仍然拒绝的原因
G3	Hamming	测序插入 1%	长度或逆映射错误
G4	Hamming	测序删除 1%	同步及缺片问题
G5	Hamming	整组丢失 20%	丢失片号及覆盖率

1%在界面中输入1，不是0.01。概率决定随机发生率，不保证实际事件数恰为序列长度的1%。两种ECC的DNA长度不同，同种子也不代表注入同一组事件；结论应同时比较实际事件数、覆盖率与文件CRC，不能保证G2一定成功。

任务 3 分析不同错误类型对数据恢复的影响

1. 使用“载入 256 字节样本”，Vanilla、Hamming 纠错、载荷 24 B、空前后缀、编码种子 42；该样本应分为 11 片。

2. 点击下载编码 FASTA，获得 encoded.fasta，复制该文件，创建可修改副本，共 8 份，分别以“实验编号 + encoded”重命名。同时点击下载参数 manifest.json，获得 manifest.json 文件

3. 使用 vscode 或记事本打开对应实验编号的 encoded.fasta 副本，执行具体操作。

4. 在 03 解码恢复中，上传对应编号的修改后的 encoded.fasta 副本文件，以及对应的 manifest.json。

5. 点击执行解码，观察执行结果

实验编号	操作	具体操作	恢复片数	能否完全恢复
1	无操作	无	____ / ____	____
2	替换	read_000001 任意一个碱基 A 替换为 T	____ / ____	____
3	删除		____ / ____	____
4	插入		____ / ____	____
5	替换 + 删除		____ / ____	____
6	替换 + 插入		____ / ____	____
7	删除 + 插入		____ / ____	____
8	替换 + 删除 + 插入		____ / ____	____

报告中需要提供 Vanilla 编码和 Church 编码对应的两个表格