

第1周 第2课时 现代计算系统结构与算力技术

冯·诺依曼架构与三大瓶颈


Von Neumann Architecture and Its Bottlenecks

主讲人：焦庆春、刘德康

自动化与电气工程学院

智能科学与技术系

核心问题：从存储程序到现代计算系统的演进动力






□ 为什么长期采用冯·诺依曼架构？为什么它会在性能扩展中形成一系列瓶颈？

- | | | |
|----|-------------|---------------------|
| 01 | 存储程序与五大部件协同 | 讲义1.1.4 · P17 – P19 |
| 02 | 现代计算系统的层次结构 | 讲义1.3 · P20 – P23 |
| 03 | 数据搬运瓶颈与三堵墙 | 讲义1.4 · P24 – P28 |
| 04 | 架构转型与三角动力模型 | 讲义1.4.3 · P27 - 28 |

- ENIAC完成了电子化，但换任务仍需重新配置硬件
- 问题：怎样让同一台机器快速执行不同任务
- 转折：程序从物理连线变成可存储、可读取的二进制信息

重新布线：为每个任务重新配置硬件




物理连线复杂 | 切换任务耗时 | 灵活性差


转折



程序进入存储器：可存储、可读取




程序以二进制存储 | 可读取并自动执行 | 快速切换任务





注意：编码同质不等于运行时语义相同



数据流 + 控制流 = 形成信息处理闭环

□ 指令流：


存储器 → 控制器

□ 控制流：

控制器 → 运算器、存储器与I/O

□ 数据流：

输入、存储器、运算器、输出之间传递




架构的核心是部件间信息交换的规则




循环往复，程序获得自动执行能力

01 用 “2 + 3” 走完一次五部件协同




价值：统一、简单、可编程，形成通用计算机蓝图

约束：处理器与存储器分离，数据必须往返搬运



问题：当计算越来越快，集中式数据通路还能同步扩展吗？



硬件提供可执行的物理资源

提供计算、存储和I/O等基础能力，是性能与能效的物理边界



固件完成初始化与底层接口抽象


通过BIOS/UEFI与驱动，实现硬件抽象与设备管理




软件通过操作系统和应用组织用户任务

操作系统提供系统服务，应用面向用户完成任务与输出


上层提高可编程性，下层决定性能边界



接口相对稳定




组成与实现持续演进




瓶颈不是容量不足，而是数据供给跟不上计算

权重与激活在层次间反复搬运（远距离、耗能高、延迟大）



数据搬运瓶颈直接决定了AI训练和推理的实际效率与成本

共同根本原因：系统各部分的扩展速度不一致



存储墙


计算速度增长快于
数据供给


功耗墙


晶体管频率增长快
于供电散热能力

ILP墙

硬件复杂度增长快于
可利用指令并行性







存储程序

五大部件

三堵墙

架构回应

指令与数据进入统一可寻址空间

控制流与数据流完成自动执行

共同限制单核持续扩展

多核、异构、专用三角动力模型

思考 如果给CPU增加更多执行单元，性能为什么不一定同比提高？

第一次作业：讲义P23，**思考题 3、8、9、10、11；**

提交方式：邮箱 icecream_tnak@163.com；截止时间：2026年9月22日

谢谢

Thank you

